

OPERAÇÕES DE AGREGAÇÃO

Para Ciência de Dados

Unifor

Resposta — Questão da Aula 7



Dado o DataFrame `df` com as colunas 'idade' e 'cidade', qual código retorna corretamente os registros com idade maior que 25 E cidade igual a 'Fortaleza'?

A `df[df['idade'] > 25, df['cidade'] == 'Fortaleza']`

B `df[(df['idade'] > 25) & (df['cidade'] == 'Fortaleza')]`

C `df[df['idade'] > 25 and df['cidade'] == 'Fortaleza']`

D `df[df['idade'] > 25 | df['cidade'] == 'Fortaleza']`

Resposta: B — Em Pandas, múltiplas condições usam & (AND) e cada condição deve estar entre parênteses.

Objetivos da Aula

Métodos de Agregação

Aprender a resumir dados com `.mean()`, `.sum()`, `.max()`, `.min()` e `.count()`.

Contar Valores Únicos

Usar o `.value_counts()` para ver a frequência de cada valor em uma coluna.

Agrupar com `groupby()`

Agrupar linhas por uma categoria e aplicar agregações em cada grupo.

Agregações Múltiplas

Aplicar mais de uma função de agregação ao mesmo tempo com `.agg()`.

Análise por Categoria

Comparar grupos diferentes dentro de um mesmo DataFrame.

Parte Prática

Consolidar tudo em um exemplo real com um dataset de funcionários.

O que são Operações de Agregação?

Definição:

- Resumem um conjunto de dados em um único valor.
- Respondem perguntas como: qual a média? qual o total?
- São aplicadas a colunas numéricas ou grupos.

Pense em uma tabela com 1.000 vendas. Em vez de olhar linha por linha, você usa agregações para responder em segundos: qual o total vendido? qual a média por loja?

Principais funções:

`.mean()`

Média aritmética

`.sum()`

Soma total

`.max()`

Maior valor

`.min()`

Menor valor

`.count()`

Contagem de valores não nulos

`.value_counts()`

Frequência de cada valor único

Métodos Básicos de Agregação

Média — .mean()

```
# Média salarial
df['salario'].mean()
# Saída: 4250.0
```

Soma — .sum()

```
# Total de vendas
df['vendas'].sum()
# Saída: 127500
```

Máximo — .max()

```
# Maior salário
df['salario'].max()
# Saída: 9800.0
```

Mínimo — .min()

```
# Menor salário
df['salario'].min()
# Saída: 1500.0
```

Dica:

Você pode aplicar essas funções diretamente no DataFrame inteiro para obter a agregação de todas as colunas numéricas de uma vez:

`df.mean()` | `df.sum()` | `df.describe()` (estatísticas completas)

Contando Valores — `.value_counts()` e `.describe()`

`.value_counts()`

Conta quantas vezes cada valor aparece em uma coluna:

```
df['cidade'].value_counts()
```

```
# Saída:  
# Fortaleza    45  
# Recife      30  
# Natal        25
```

Proporção com `normalize=True`:

```
df['cidade'].value_counts(normalize=True)
```

```
# Saída em percentual:  
# Fortaleza    0.45  
# Recife      0.30
```

`.describe()`

Gera um resumo estatístico completo de uma vez:

```
df['salario'].describe()
```

```
# count      100.0  
# mean       4250.0  
# std        1320.5  
# min        1500.0  
# 25%        3200.0  
# 50%        4100.0  
# 75%        5300.0  
# max        9800.0
```

Agrupamento com groupby()

Como funciona:

1. Divide o DataFrame em grupos por categoria.
2. Aplica uma função em cada grupo.
3. Combina os resultados em uma tabela.

Sintaxe:

```
df.groupby('coluna_grupo')['coluna'].funcao()
```

Exemplos práticos:

Média por cidade

```
df.groupby('cidade')['salario'].mean()
```

Total por categoria

```
df.groupby('cargo')['vendas'].sum()
```

Contagem por grupo

```
df.groupby('cidade')['nome'].count()
```

Múltiplas funções

```
df.groupby('cargo')['salario'].agg(['mean', 'max', 'min'])
```

Parte Prática — Aplicando Agregações

```
import pandas as pd

df = pd.read_csv('funcionarios.csv')

# Métodos básicos na coluna salário
df['salario'].mean()      # média
df['salario'].sum()       # soma total
df['salario'].max()       # maior valor
df['salario'].min()       # menor valor

# Frequência de cidades
df['cidade'].value_counts()

# Resumo estatístico completo
df['salario'].describe()

# Agrupamento: média salarial por cidade
df.groupby('cidade')['salario'].mean()

# Agrupamento com múltiplas funções
df.groupby('cargo')['salario'].agg(['mean', 'max', 'min'])
```


Questão — Aula 8



Dado o DataFrame `df` com uma coluna `'salario'`, qual código retorna a média salarial agrupada por `'cidade'`?

A

```
df['salario'].mean('cidade')
```

B

```
df.groupby('cidade')['salario'].mean()
```

C

```
df.groupby('salario')['cidade'].mean()
```

D

```
df['cidade'].groupby('salario').mean()
```