



PYTHON

Para Ciência de Dados



Unifor

Resultados Esperados



Dominar o Pandas:

Aprenda a utilizar a principal biblioteca do Python para manipulação de Dados Tabulares.



Explorar e Entender a Estrutura De Um DataFrame

Entender na prática como o Python organiza as informações usando as estruturas fundamentais do Pandas: as Series (Uma única coluna) e os DataFrames (A Tabela Completa)



Trabalhar com Diferentes Tipos de Informação

Identificar e Manipular Corretamente os Diferentes Tipos de Dados Presentes no Pandas (Como Textos, Números Inteiros e Dados).




Importar Bases de Dados Reais

Trazer dados do Mundo real para dentro do seu Código, Realizando a Leitura de Arquivos em Formatos Muito Comuns no Mercado, como CSV e Excel (.xls ou .xlsx)



Navegar e Extração

Seleção Específica de Linhas e Colunas, Além da criação de Filtros e Consultas.



Preparando os Dados para Análise

Operações Básicas de Agregação para Análises Iniciais




DADOS



Unifor

O que são Dados ?



A matéria-prima do mundo digital.

Pedaços de informações soltas: números, textos, cliques, curtidas, fotos.

Sozinhos, não têm significado claro.

Analogia



Imaginem uma caixa gigante cheia de peças de Lego jogadas no chão. Tem peça azul, vermelha, grande, pequena... Tudo misturado. Essas peças soltas são os dados. Se você olhar para uma pecinha vermelha sozinha, ela não serve para muita coisa, você não sabe o que ela é. Dados são exatamente isso: rastros que deixam todos os dias na internet (uma curtida, uma compra, um tempo de tela), mas que, bagunçados, são apenas 'peças no chão'




DADOS TABULARES

Para Ciência de Dados



Unifor

O que são Dados Tabulares (ou Estruturados) ?



Informações organizadas em linhas e colunas .

Cada linha é um registro único; cada coluna é uma característica.


O formato mais comum no mundo corporativo (planilhas e bancos de dados).



Dados tabulares são informações organizadas em um formato estruturado de linhas e colunas. Cada linha representa um registro individual (uma observação), enquanto cada coluna define uma variável ou atributo específico desse registro. Essa estrutura padronizada facilita a análise, a comparação de dados e a tomada de decisões estratégicas em áreas como negócios, ciência e aprendizado de máquina.

Tudo sobre Dados Tabulares: Estrutura, Manipulação e Aplicação

1. Estrutura e Formatos Básicos




O que são Dados Tabulares?
Organizados em linhas e colunas. Cada linha é um registro (ex. cliente), cada coluna é um atributo (ex. idade, nome).



Formatos de Armazenamento
Lidos de arquivos CSV, planilhas Excel, bancos de dados relacionais, `.read_csv()`, `.info()`, `.describe()`




Limpeza Inicial de Dados
Tratamento de valores nulos (NaN) e identificação de valores fora do padrão. `.dropna()`, `.fillna()`



Remoção de Duplicatas
Garantia da integridade dos dados, removendo registros redundantes. `.drop_duplicates()`

2. Manipulação e Transformação



Seleção e Filtragem
Acesso preciso a dados com base em índices (`.loc`) ou posições (`.iloc`), e condições lógicas.




Engenharia de Atributos (Recursos)
Criação de novos atributos (ex: cálculo de taxas, extração de datas) a partir dos existentes.



Cor	Car_vermelho	Car_azul	Car_azul	Car_azul
Cor	1	0	0	0
Azul	0	1	0	0
Vermelho	0	1	0	1
Cor_azul	0	1	1	0

Codificação de Dados Categóricos
Conversão de variáveis de texto para numéricas para uso em análises e modelos (ex: One-Hot, Label Encoding).

3. Análise e Saída para Consumo



Visualização e Exploração
Geração de gráficos integrados e uso de bibliotecas de visualização para entender os dados.



Agregação e Sumarização
Agrupamento de dados (`.groupby()`) e criação de tabelas dinâmicas (`.pivot_table()`) para análises estatísticas.



Preparação para Aplicação (Saída)
Divisão de dados para modelos de aprendizado de máquina (X: recursos, y: alvo) ou exportação.



PANDAS

Para Ciência de Dados



Unifor

O que é o Pandas?



O Pandas é uma das Bibliotecas Mais Populares de Código Aberto Para a Linguagem Python, Focada em Manipulação, Análise e Limpeza de Dados Estruturados. Ele oferece Estruturas de Alta Performance, Como DataFrame (Tabelas) e Series

Vantagens



Eficiência e Produtividade

Tarefas complexas de manipulação que exigiriam dezenas de linhas de código nativo podem ser executadas com apenas um ou dois comandos, economizando tempo.



Limpeza e Tratamento de Dados:

Permite organizar, filtrar, ordenar e modificar dados de forma simples usando estruturas como DataFrame e Series.



Trabalhar com Diferentes Tipos de Informação

Identificar e Manipular Corretamente os Diferentes Tipos de Dados Presentes no Pandas (Como Textos, Números Inteiros e Dados).



Versatilidade de Formatos

Trazer dados do Mundo real para dentro do seu Código, Realizando a Leitura de Arquivos em Formatos Muito Comuns no Mercado, como CSV e Excel (.xls ou .xlsx)



Integração com o Ecossistema Python

Integra-se perfeitamente com bibliotecas essenciais como NumPy (cálculos numéricos), Matplotlib/Seaborn (visualização de dados) e Scikit-Learn (Machine Learning).





Comunidade e Suporte



Por ser a ferramenta mais utilizada na área de dados, possui uma comunidade vasta e consolidada, facilitando encontrar ajuda, documentação e soluções para problemas

Pandas no Pipeline de Ciência de Dados: Do Dado Bruto ao Modelo

1. Aquisição e Preparação



2. Transformação e "Feature Engineering"



3. EDA e Saída para Modelagem





OBRIGADO !

Para Ciência de Dados



Unifor